

MAKALAH SEMINAR HASIL TUGAS AKHIR
IDENTIFIKASI LAHAN PERTANIAN MENGGUNAKAN CONVOLUTIONAL
NEURAL NETWORK (CNN) PADA CITRA GOOGLE EARTH

IDENTIFICATION OF PADDY FIELDS USING CONVOLUTIONAL NEURAL NETWORK
(CNN) ON GOOGLE EARTH IMAGES

Fendy Prayogi¹, Imron Rosyadi, S.T., M.Sc.², Farida Asriani, S.Si., M.T.³

Jurusan Teknik Elektro, Fakultas Teknik, Universitas Jendral Soedirman

Jl. Mayjend Sungkono Km 5, Blater, Purbalingga 53371

Mahasiswa Pemakalah¹, Dosen Pembimbing I², Dosen Pembimbing I³

Abstrak - Masyarakat Indonesia umumnya dikenal sebagai masyarakat agraris, karena hampir sebagian besar dari penduduk Indonesia memiliki status pekerjaan dalam sektor pertanian sebesar 35.703.074 jiwa. Namun identifikasi suatu area lahan pertanian masih dengan metode tradisional dilakukan dengan survei lapangan, dan memerlukan banyak waktu maupun biaya. *Deep learning* menjadi pembelajaran fitur dan pengklasifikasi suatu objek secara bersamaan, dan menggunakan data pelatihan dengan metode CNN yang dinilai efektif dalam berbagai pengenalan. Proses dalam deteksi lahan pertanian sawah pada citra *Google Earth Pro* dilakukan dengan mengidentifikasi berbagai objek yang melibatkan citra yang kompleks dan variatif. Kemudian datasheet dikelola pada *Google Colaboratory* untuk dilatih dan didapatkan model, serta diaplikasikan hasilnya dalam pengujian citra. Terdapat dua arsitektur CNN yang digunakan *LeNet-5* dan *VGG-16Net*, sehingga akan dibandingkan hasil perbandingan dari pemilihan arsitektur tersebut. Berdasarkan objek yang berukuran sangat kecil dengan metode CPM dapat menghasilkan potongan citra menjadi 89.100 citra yang berukuran 56x56 piksel. Perbandingan kurva akurasi dan kegagalan menunjukkan kedua arsitektur dalam kondisi *goodfit*, namun asitektur *LeNet-5* Modifikasi memiliki hasil yang lebih baik dalam pelatihan dengan akurasi akhir sebesar 0.993 dan kegagalan 0.019 dibandingkan dengan arsitektur *VGG-16Net* yang akurasi diperoleh 0.992 dan kegagalan 0.022 dalam skala nilai 0 sampai 1.

Kata kunci : Identifikasi, *Deep Learning*, *Convolution Neural Network* (CNN), *Google Earth*

Abstract - *Indonesian society is generally known as an agrarian society, because almost the majority of Indonesia's population has employment status in the agricultural sector of 35,703,074 people. However, identification of an agricultural land area is still done by traditional methods carried out by field surveys, and requires a lot of time and money. Deep learning becomes learning features and classifying an object simultaneously, and using training data with the CNN method which is considered effective in various introductions. The process of detecting paddy fields in Google Earth Pro imagery is carried out by identifying various objects that involve complex and varied imagery. Then the obtained datasheet is managed at Google Collaboratory to be trained and obtained by the model, and the results are applied in image testing. There are two CNN architectures used by LeNet-5 and VGG-16Net, so that the results of the architectural selection will be compared. Based on very small objects using the CPM method can produce image slices into 89,100 images measuring 56x56 pixels. Comparison of accuracy and failure curves shows both architectures in goodfit conditions, but the LeNet-5 Modified architecture has better results in training with a final accuracy of 0.9936 and failure of 0.0193 compared to VGG-16Net architecture where accuracy is obtained by 0.9923 and failure by 0.0229 on a scale of values of 0 until 1.*

Keywords : *Identification, Convolution Neural Network (CNN), Google Earth, Deep Learning*

I. PENDAHULUAN

1.1. Latar Belakang

Masyarakat Indonesia umumnya dikenal sebagai masyarakat agraris, karena hampir sebagian besar dari penduduk Indonesia memiliki status pekerjaan dalam sektor pertanian sebesar 35.703.074 jiwa. Dikarenakan secara kebutuhan pokok pangan, padi menjadi salah satu jenis tanaman budidaya dan sumber daya alam yang bermanfaat bagi manusia[1].

Identifikasi dan pemetaan vegetasi di suatu area diperlukan untuk lingkup penelitian ilmu pengetahuan dan pengelolaan sumber daya alam. Namun identifikasi suatu area lahan pertanian masih dengan metode tradisional dilakukan dengan survei lapangan, dan memerlukan banyak waktu maupun biaya. Teknologi penginderaan jauh sudah diterapkan Indonesia dikelola oleh Badan Pusat Statistik (BPS) dengan metode estimasi produksi padi yang lebih objektif melalui Kerangka Sampel Area (KSA).

Deep learning menjadi pembelajaran fitur dan pengklasifikasi suatu objek secara bersamaan, dan menggunakan data pelatihan dengan metode CNN yang dinilai efektif dalam berbagai pengenalan. Arsitektur CNN dibagi menjadi tiga bagian, yaitu lapisan konvolusional, fungsi aktivasi (Relu), dan lapisan max pooling. Penelitian terbaru menunjukkan bahwa CNN efektif untuk beragam aplikasi [5].

Proses dalam deteksi lahan pertanian sawah pada citra *Google Earth Pro* dilakukan dengan mengidentifikasi berbagai objek yang melibatkan citra yang kompleks dan variatif. Dengan menggunakan metode *convolutional neural networks* (CNN) digunakan karena dapat menangani masalah yang kompleks tersebut dan memiliki kinerja yang baik dari hasil penelitian terkait.

Dengan latar belakang tersebut, penulis menyelidiki potensi untuk penulis mengajukan kerja dengan judul “Identifikasi Lahan Pertanian Menggunakan *Convolutional Neural Network* (CNN) Pada Citra *Google Earth*”.

1.2. Rumusan Masalah

Dari latar belakang yang telah diuraikan di atas dapat dikemukakan rumusan masalah sebagai berikut :

1. Bagaimana arsitektur CNN untuk melakukan identifikasi lahan pertanian pada citra *Google Earth* ?
2. Bagaimana unjuk kerja arsitektur CNN dalam melakukan pelatihan dan pengujian dalam proses identifikasi lahan pertanian ?

1.3. Batasan Masalah

Agar Tugas Akhir lebih fokus dan terarah, maka perlu adanya batasan masalah. Adapun batasan masalah dalam tugas akhir ini sebagai berikut :

1. Metode *deep learning* yang digunakan untuk lahan pertanian menggunakan CNN (*Convolutional Neural Network*).
2. Dataset gambar geografis diambil melalui layanan *Google Earth Pro*.
3. Jumlah dataset pada pelatihan dan validasi memiliki rasio 75:25, serta pada implementasi identifikasi lahan sawah dataset pengujian hanya pada satu citra.
4. Secara umum citra diambil melalui ketentuan, yaitu lahan sawah basah atau terlihat pada citra berwarna hijau, ketinggian 100 meter dan 300 meter, lahan sawah dan bukan lahan sawah, resolusi dimensinya 1116x632 piksel berformat “.jpg” dan minimal kedalaman bit (*bit depth*) sebanyak 24 bit.
5. Pada dataset pengujian terdapat tiga wilayah di Indonesia, berupa di pulau Jawa, Kalimantan, dan Sumatra. Lokasi spesifiknya di pulau Jawa terdapat pada Kabupaten Banyumas, di pulau Kalimantan terdapat pada Kabupaten Tanah Laut Kalimantan Selatan, dan di pulau Sumatra terdapat di Kabupaten Ogan Sumatra Selatan.
6. Pengambilan citra berdasarkan ketinggian (*eye alt*) hanya menyesuaikan ukuran dari *Google Earth* dan citra yang dikumpulkan dalam

keadaan cerah maupun jelas terlihat lahan sawah tanpa menyetarakan waktu pengambilan citra di seluruh dataset.

7. Program yang dirancang menggunakan Bahasa Pemrograman *Python* dan memiliki file berformat “.ipynb” atau *IPython Notebooks*.
8. Antarmuka melalui *Google Colaboratory* dengan spesifikasi yang digunakan saat penelitian ini dilakukan.
9. Pembuatan model deep learning pada identifikasi vegetasi pertanian menggunakan Framework *Keras* dan *TensorFlow*.

1.4. Tujuan dan Manfaat

1.4.1 Tujuan

Tugas Akhir ini memiliki beberapa tujuan sebagai berikut :

1. Merancang arsitektur CNN untuk identifikasi lahan pertanian.
2. Melakukan proses pelatihan dan pengujian dalam pemodelan arsitektur CNN.

1.4.2 Manfaat

Manfaat yang diharapkan setelah penelitian ini dilaksanakan adalah sebagai berikut :


1. Meminimalkan kesalahan yang dilakukan oleh manusia, maupun lembaga statistika dalam mendeteksi luas lahan pertanian.
2. Mendeteksi lahan pertanian di suatu wilayah menjadi lebih akurat dengan menggunakan metode CNN dibandingkan dengan metode penelitian lain.
3. Menawarkan solusi yang lebih murah dan efisien dalam identifikasi lahan pertanian khususnya di Indonesia, maupun area geografis di daerah lainnya.

II. TINJAUAN PUSTAKA

2.1. Deep Learning

Deep Learning merupakan cabang dari *Machine Learning* yang terinspirasi dari korteks

manusia dengan menerapkan jaringan syaraf buatan yang memiliki banyak *hidden layer*[4].



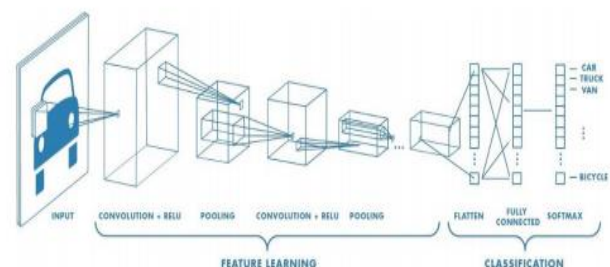
Gambar 2. 1 Layer pada Deep Learning[4]

2.2. Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah salah satu algoritma dari deep learning yang merupakan pengembangan dari *Multilayer Perceptron* (MLP) yang dirancang untuk mengolah data dalam bentuk dua dimensi, misalnya gambar atau suara. Lapisan-lapisan CNN memiliki susunan neuron 3 dimensi (lebar, tinggi, kedalaman). Lebar dan tinggi merupakan ukuran lapisan sedangkan kedalaman mengacu pada jumlah lapisan[8].

2.2.1 Arsitektur Convolution Neural Network

Arsitektur dari CNN dibagi menjadi 2 bagian besar, *Feature Extraction Layer* dan *Fully-Connected Layer* (MLP). Berikut ini diperlihatkan pada Gambar 2.2 yang merupakan arsitektur CNN.



Gambar 2. 2 Arsitektur CNN[9]

a. Feature Extraction Layer

Proses yang terjadi pada bagian ini adalah melakukan “*encoding*” dari sebuah *image* menjadi *features* yang berupa angka-angka yang merepresentasikan *image* tersebut (*Feature Extraction*). *Feature extraction layer* terdiri dari dua


bagian *Convolutional Layer* dan *Pooling Layer* [9].

b. *Fully-Connected Layer*

Lapisan *Fully-Connected* adalah lapisan di mana semua neuron aktivasi dari lapisan sebelumnya terhubung semua dengan neuron di lapisan selanjutnya seperti halnya jaringan saraf tiruan biasa. Setiap aktivasi dari lapisan sebelumnya perlu diubah menjadi data satu dimensi sebelum dapat dihubungkan ke semua neuron di lapisan.

c. *Arsitektur LeNet-5*


LeNet-5 adalah salah satu arsitektur paling sederhana dalam CNN yang memiliki 2 *convolution layer* dan 3 *fully-connected layer*. Rata-rata lapisan *max pooling* seperti yang dikenali sekarang disebut lapisan *sub-sampling* dan memiliki bobot yang dapat dilatihkan. Arsitektur ini memiliki sekitar 60.000 parameter [6].



Gambar 2. 3 Arsitektur LeNet-5

d. *Arsitektur VGG-16Net*

VGG-16 Network adalah arsitektur *Convolutional Neural Network* terdapat *Convolutional layer* yang digunakan dalam arsitektur ini ada 2 jenis, yaitu *convolutional layer* dengan ukuran filter 3x3 (*conv3*) dan ukuran filter 1x1 (*conv1*). Ukuran *convolutional layer* yang digunakan bermacam-macam, yaitu 64x64, 128x128, 256x256, dan 512x512[20].



Gambar 2. 4 Konvolusi pada Arsitektur VGG-16Net

2.3. Konsep Neural Network


2.3.1 Struktur Neural Network

Ide mendasar dari *Artificial Neural Network* (ANN) adalah mengadopsi mekanisme berpikir sebuah sistem atau aplikasi yang menyerupai otak manusia, baik untuk pemrosesan berbagai sinyal elemen yang diterima, toleransi terhadap kesalahan/error, dan juga *parallel processing*[12].

2.3.2 Fungsi Aktifasi (*Activation Function*)

Sesuai dengan namanya, *activation function* berfungsi untuk menentukan apakah neuron tersebut harus “aktif” atau tidak berdasarkan dari weighted sum dari input[13].

a. ReLU (*Non-Linear*)



Gambar 2. 5 ReLU (*Non-Linear*)


Pada Gambar 2.5 merupakan fungsi aktivasi pada ReLU melakukan “*threshol*” dari 0 hingga infinity. ReLU juga dapat menutupi kelemahan yang dimiliki oleh *Sigmoid* dan *Tanh*. Sebenarnya masih banyak activation function yang lain, namun beberapa fungsi yang disebutkan diatas merupakan fungsi yang sering digunakan [13].

2.4. Metode Sliding Window

Sliding Window merupakan sebuah metode yang paling umum digunakan dalam pemrosesan citra digital. Proses ini digunakan untuk mempermudah dalam mengekstraksi sebuah fitur secara lokal maupun untuk membentuk sebuah informasi. Dengan kata lain, *sliding window* adalah sebuah metode yang menggunakan window yang bergeser sebesar ukuran perpindahannya untuk mempermudah atau memperkecil komputasi yang dilakukan[18].

2.5. Metode Pencacahan Citra (*Chopping Picture Methode*)

Metode pencacahan citra atau yang disebut *chopping picture methode* (CPM) merupakan metode yang digunakan untuk mengidentifikasi objek yang tergolong berukuran kecil, dan secara umum tidak dikenali melalui pengelihat manusia. Metode CPM dapat diterapkan untuk pengamatan visual tanaman dalam berbagai skala, seperti fotografi lapangan (dalam penelitian ini), fotografi drone, fotografi pesawat terbang seperti Google Earth, dan gambar satelit [19].



Gambar 2. 6 Hasil CPM beresolusi 56x56 piksel

2.6. Google Colaboratory

Google Colaboratory atau yang dikenal *Colaboratory* adalah sebuah layanan gratis dalam lingkup Jupyter notebook yang tidak memerlukan pengaturan dan sepenuhnya berjalan di cloud [14]. Dengan *Colaboratory* pengguna dapat menulis dan mengeksekusi kode, menyimpan dan membagikan analisis, serta mengakses sumber daya komputasi yang kuat, dimana semuanya gratis dari browser pengguna.

2.7. Keras dan TensorFlow

Keras adalah jaringan saraf tingkat tinggi memiliki *Application Programming Interface* (API), dalam bahasa pemrograman *Python* dan mampu berjalan di atas *TensorFlow*, *CNTK*, atau *Theano. Framework* ini dikembangkan dengan fokus pada memungkinkan eksperimen cepat. Mampu beralih dari ide ke hasil dengan penundaan sesedikit mungkin menjadi kunci untuk melakukan penelitian yang baik [15].

Pada GPU, *TensorFlow* melibatkan *library* operasi *deep learning* yang

dioptimalkan dengan baik yang disebut *Library NVIDIA CUDA Deep Neural Network* (cuDNN).

2.8. Google Earth Pro

Google Earth Pro adalah alat yang sangat baik untuk membuat dan mendistribusikan visualisasi data geografis[16]. Pengguna akan belajar cara menggunakan *Google Earth* untuk melampirkan informasi penting ke fitur Anda termasuk foto, video, tautan ke file PDF dan situs web, teks, dan banyak lagi. Kemudian juga akan belajar cara membuat peta tematik, peta 3D, alamat *geocode*, membuat profil elevasi dan *viewsheds*, menambahkan citra sendiri, menggunakan citra historis dari berbagai lokasi, dan lain-lain.

III. METODELOGI PENELITIAN

3.1. Tempat Penelitian

Penelitian dilaksanakan dalam masa waktu 4 bulan yang dimulai pada bulan Oktober 2019 sampai dengan Januari 2020 dan bertempat di Kampus Teknik Kabupaten Purbalingga, Universitas Jenderal Soedirman.

3.2. Alat dan Bahan

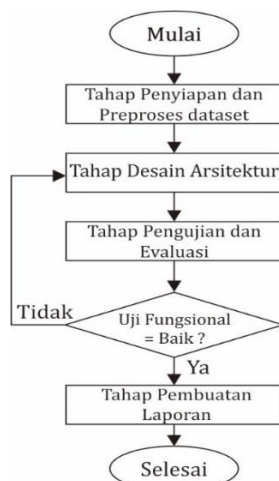
Daftar alat dan bahan yang digunakan selama penelitian ini adalah sebagai berikut.

1. Perangkat Keras :
 - a. Sebuah Laptop Asus Vivobook X442UR dengan spesifikasi prosesor Intel Core i5-7200U CPU @2.50 Hz, RAM 4 GB, dan Harddisk 1 TB, serta VGA Nvidia GeForce 930MX.
 - b. Komputer virtual *Google Colaboratory* dengan spesifikasi GPU: 1x Tesla K80, komputasi 3.7, mempunyai inti CUDA 2496 , 12 GB GDDR5 VRAM, CPU: 1x single core hyper threaded Xeon Processors @2.3 Ghz, RAM: ~12.6 GB, Disk: ~33 GB.
2. Perangkat Lunak :
 - a. Sistem operasi Windows 10 64 bit.
 - b. *Google Earth Pro* versi 7.3.2.5776 64 bit.

- c. Peramban Web *Google Chrome* versi 78.0.3904.97 64 bit.
 - d. *Google Colaboratory* (*Jupyter Notebook* versi *cloud*).
 - e. Layanan Repositori Web *Development* pada Platform *Github*.
3. Alat pengukur panjang, berupa Meteran digunakan untuk mengukur panjang lahan dan sebagai pembukti validitas meter dalam piksel.
 4. Dataset yang digunakan untuk pelatihan dan pengujian berupa sampel gambar geografis lahan pertanian yang diambil dari *Google Earth* memiliki ketinggian 100 meter dan 300 meter, serta objek lahan sawah dan bukan lahan sawah dengan resolusi dimensinya 1116x632 piksel berformat “.jpg” dan kedalaman bit (*bit depth*) sebanyak 24 bit.
 5. Program yang dibuat memiliki *sourcecode* berbahasa pemrograman *python* dan memiliki format “.ipynb” atau *IPython Notebooks*, sehingga dapat diakses maupun melakukan eksekusi di dalam browser secara langsung.

3.3. Metode dan Alur Penelitian

Untuk penjelasan dalam metode dan alur penelitian ini dilakukan melalui beberapa tahapan yang dimulai dari tahap penyiapan dan preproses dataset, dilanjutkan dengan tahap desain arsitektur dataset. Kemudian dilakukan tahap pengujian dan evaluasi sistem. Pada tahap terakhir yaitu tahapan pembuatan laporan penelitian.



Gambar 3. 1 Diagram Alir Penelitian

Penelitian ini dilaksanakan melalui beberapa tahapan sebagai berikut :

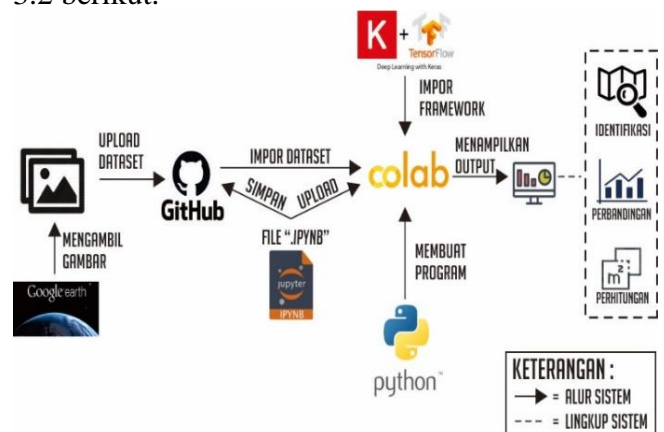
3.3.1 Tahap Penyiapan dan Preproses Dataset

Pada tahap penyiapan ini digunakan untuk menyiapkan alat dan bahan yang diperlukan selama penelitian. Alat dan bahan tersebut berupa perangkat keras laptop dan software *Google Earth Pro*, serta peramban web *Google Chrome* yang digunakan untuk akses masuk pengolahan data berbasis cloud pada *Google Colaboratory*. Selain itu, penulis juga mengumpulkan berbagai informasi melalui studi pustaka.

Sedangkan pada tahap preproses dataset dilakukan dengan mengambil citra geografis wilayah di tiga lokasi pulau yang terdapat lahan persawahan, yaitu Jawa, Kalimantan, dan Sumatra dari *Google Earth Pro* diambil pada ketinggian 100 meter dan 300 meter. Kemudian datasheet ini akan dikelola pada proses identifikasi lahan pertanian melalui *Google Colaboratory*.

3.3.2 Tahap Desain Arsitektur

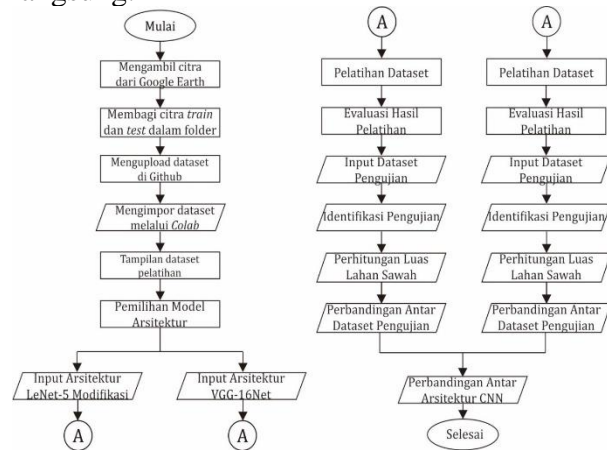
Tahap ini berfungsi untuk menunjukkan gambaran kerja dari sistem yang dibuat oleh penulis berdasarkan hasil studi pustaka dan diskusi dengan dosen pembimbing. Hasil perencanaan desain sistem yang diusulkan pada penelitian ini dapat dilihat pada Gambar 3.2 berikut.



Gambar 3. 2 Diagram Infrastruktur Sistem

Setelah menyiapkan alat dan bahan yang diperlukan selama penelitian, serta diperoleh *datasheet* untuk pelatihan dan pengujian pada *Google Colaboratory*. Proses awal yang

dilakukan dengan membuat satu folder yang berisikan datasheet, lalu diupload pada situs *Github* melalui repositori akun user. Selain itu juga terdapat file “.ipynb” sebagai dokumen proyek file ini yang berisi artikel dan proses pemrograman dalam bahasa *python* yang akan dieksekusi di dalam web browser secara langsung.



Gambar 3. 3 Diagram Alir Sistem

Pada *Google Colaboratory* dapat dibuka file proyek tersebut melalui *Github*, lalu dilakukan tahap eksekusi file. Kemudian pada dataset akan tersimpan dan dilatih menggunakan metode deep learning CNN sampai dengan panjangnya epoch yang ditentukan. Arsitektur CNN yang digunakan yaitu *LeNet-5* dan *VGG-16Net*. Karena pada dataset pengujian terdapat 3 jenis lokasi sawah yang berbeda, kemudian ketiga lokasi tersebut dibandingkan dengan parameter yang ditentukan menjadi sebuah grafik. Begitu pun hasil perbandingan dari pemilihan arsitektur yang berbeda akan dibandingkan seberapa efisien penggunaan arsitekturnya. Kemudian jika nilai akurasi masih rendah dan nilai kesalahan masih tinggi maka perlu diubah parameter citra dan modelnya.

3.3.3 Tahap Pengujian dan Evaluasi.

Tahap ini penulis melakukan pengujian keseluruhan terhadap sistem yang telah dirancang untuk mendapatkan hasil uji berdasarkan metode CNN dari pengolahan data pelatihan. Sistem akan diuji apakah sudah sesuai yang diharapkan atau belum. Pengujian ini akan menghasilkan output berupa identifikasi lahan pertanian yang diujikan, dan

perbandingan hasil pengujian terhadap tiga lokasi sawah yang berbeda serta nilai luas lahannya. Setelah tahap pengujian selesai, hasil pengujian digunakan sebagai bahan evaluasi terhadap sistem yang dibangun.

3.3.4 Tahap Pembuatan Laporan

Tahap laporan adalah tahap terakhir dalam penelitian ini. Setelah sistem menghasilkan keluaran sesuai dengan yang diharapkan, maka disusunlah laporan yang berjudul “IDENTIFIKASI LAHAN PERTANIAN MENGGUNAKAN *CONVOLUTIONAL NEURAL NETWORK* (CNN) PADA CITRA *GOOGLE EARTH*”.

3.4. Waktu dan Jadwal Penelitian

Penelitian dilaksanakan dalam waktu 4 bulan dimulai dari bulan Oktober 2019 sampai dengan bulan Januari 2020 dengan rincian jadwal kegiatan sebagai berikut pada tabel 3.1.

Tabel 3.1 Waktu dan Jadwal Penelitian

No	Kegiatan	I				II				III				IV			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
1.	Studi Pustaka																
2.	Pengumpulan data																
3.	Perancangan sistem																
4.	Pengujian dan evaluasi sistem																
5.	Pembuatan laporan																

IV. PEMBAHASAN

4.1 Area dan Dataset Penelitian

4.1.1 Area Penelitian

Berikut ini ditampilkan tabel 4.1 dibawah ini mengenai ketiga pulau yang peneliti telah tentukan, sebagai berikut:

Tabel 4. 1 Area/Wilayah Penelitian

No .	Area Penelitian	Lokasi spesifik	Koordinat Geografis	Waktu Pengambilan Citra
1.	Pulau Jawa	Kabupaten Banyumas ,Provinsi Jawa Tengah	7°25'31.66"S 109°20'22.26"E	26-02-2019
2.	Pulau Kalimantan	Kabupaten Tanah Laut, Provinsi Kalimantan Selatan	3°46'20.79"S 114°49'28.12"E	02-03-2018
3.	Pulau Sumatra	Kabupaten Ogan Komering Ulu Timur, Provinsi Sumatra Selatan	4°10'25.59"S 104°38'59.84"E	26-07-2016

4.1.2 Dataset

Citra-citra pada *dataset* dibagi menjadi 3 jenis objek utama, yaitu citra lahan sawah, citra bukan/atau selain sawah, dan citra campuran/perpaduan antara sawah maupun bukan sawah. Kemudian dibuat folder yang digunakan sebagai dataset dengan nama, berupa folder *train*, folder *chopped*, dan folder *test*. Peneliti melakukan pelatihan *dataset* yang dimiliki dengan menggunakan metode *Chopping Picture Method* (CPM). Sehingga dilakukan pemotongan setiap citra pada *dataset* pelatihan menjadi citra dengan sangat kecil, serta ukurannya menjadi 56x56 piksel.

Tabel 4. 2 Dataset Pelatihan dan Dataset Validasi Pada Folder Chopped

Class	Objek Citra		CNN	Klasifikasi CNN	
	Area Penelitian (citra)		Folder Train	Folder Chopped	
			Dataset Pelatihan	Pelatihan	Validasi
Sawah	Jawa	25	75 citra	33.412 /	11.137 /
	Kalimantan	25		33.413 citra	11.138 citra
	Sumatra	25			
Bukan Sawah	Jawa	25	75 citra	33.412 /	11.137 /
	Kalimantan	25		33.413 citra	11.138 citra
	Sumatra	25			

Total Citra	150	150 citra	66.825 citra	22.275 citra
89100 citra				

1. Jumlah Dataset Pelatihan

Pada penelitian ini terdapat *dataset* pelatihan sebanyak 150 citra memiliki format citra berupa “.jpg”. *Dataset* pelatihan ini dibagi menjadi 2 *class*, yaitu citra sawah dan citra bukan/atau selain sawah. Kemudian setiap *class* memiliki tiga area yang berbeda dan masing-masing area berjumlah 25 citra, sehingga apabila dijumlahkan satu *class* terdapat total sebanyak 75 citra. *Dataset* pelatihan ini diambil sebanyak 75% secara acak dari folder *chopped* yang berjumlah 66.825 citra meliputi setiap *class* diambil 33.412 citra dan 33.413 citra secara acak.

2. Jumlah Dataset Validasi

Dataset validasi yang digunakan sebanyak 25% dari folder *chopped* dengan jumlah citra 22.275 citra. Sehingga jumlahnya sebanyak 11.137 citra atau 11.138 citra pada setiap *class*.

3. Jumlah Dataset Pengujian

Jumlah *dataset* pengujian yang digunakan pada folder *test* sebanyak 70 citra dengan terdapat folder-folder yang terpisah didalamnya, yaitu folder Jawa, folder Kalimantan, folder Sumatra, dan folder *test image* seperti yang terlihat pada tabel 4.3.

Tabel 4. 3 Dataset Pengujian pada Folder Test

Objek Citra		Class	
Folder Test			
Dataset Pengujian (citra)			
Jawa	20	Sawah	10 citra
		Bukan Sawah	10 citra
Kalimantan	20	Sawah	10 citra
		Bukan Sawah	10 citra
Sumatra	20	Sawah	10 citra
		Bukan Sawah	10 citra
Test Image	10		
Total Citra	70	60 citra	

4.1.3 Pengambilan Dataset

Dataset diperoleh dengan mengambil objek citra geografis wilayah di tiga lokasi pulau yang terdapat lahan pertanian sawah, yaitu Jawa, Kalimantan, dan Sumatra dari perangkat lunak *Google Earth Pro*. Terdapat dua kriteria pengambilan citra, yaitu diambil pada ketinggian 100 meter dan 300 meter. Untuk mencari area yang akan diteliti dapat dicari melalui panel pencarian, kemudian klik tombol “OK”. Karena pada fitur *Google Earth Pro* tidak terdapat cara yang dapat mengatur ketinggian dengan menginputnya, maka peneliti melakukannya melalui penganturan *zoom*/memperbesar citra dengan cursor hingga ditampilkan ketinggian yang akan digunakan.

4.2 Pelatihan dan Pengujian pada Google Colaboratory


Parameter model yang diimplementasikan dalam penelitian ini meliputi jumlah pelatihan *epoch* sebanyak 50 *epoch*, batch size pada pelatihan sebanyak 200 citra. Arsitektur CNN yang digunakan yaitu *LeNet-5* Modifikasi dan *VGG-16Net*.

4.2.1 Hasil Fluktuasi Accuracy dan Loss Selama Pembelajaran Epoch

Pada penelitian ini pengujian yang dilakukan pada Google Colaboratory terdapat empat macam kondisi atau file yang berbeda. Tujuannya untuk menguji dan membandingkan performa kedua arsitektur melakukan CNN, sehingga dapat diperoleh hasil yang terbaik dan melakukan pembelajaran terhadap gambar yang telah dipotong-potong dengan berhasil. Kemudian mengamati pengaruh kondisi dataset dari perbedaan faktor ketinggian terhadap tingkat akurasi keberhasilan dan mengidentifikasi lahan pertanian sawah.


Pada pengujian ini memiliki *epoch* dalam pemodelan sebanyak 20. Akurasi diperoleh ketika keakuratan suatu model dapat mengklasifikasi citra validasi dan *loss* menandakan ketidakakuratan atau kegagalan dalam memprediksi suatu model.

1. Hasil pelatihan dan pengujian pada arsitektur *LeNet-5* modifikasi dengan ketinggian 100 meter




Gambar 4. 1 Kurva Akurasi dan Kegagalan Pelatihan pada Dataset Pelatihan dan Validasi dengan Arsitektur *LeNet-5* Modifikasi

2. Hasil pelatihan dan pengujian pada arsitektur *LeNet-5* modifikasi dengan ketinggian 300 meter




Gambar 4. 2 Kurva Akurasi dan Kegagalan Pelatihan pada Dataset Pelatihan dan Validasi dengan Arsitektur *LeNet-5* Modifikasi

3. Hasil pelatihan dan pengujian pada arsitektur *VGG-16Net* dengan ketinggian 100 meter



Gambar 4.3 Kurva Akurasi dan Kegagalan Pelatihan pada Dataset Pelatihan dan Validasi dengan Arsitektur *VGG-16Net*

4. Hasil pelatihan dan pengujian pada arsitektur *VGG-16Net* dengan ketinggian 300 meter



Gambar 4. 4 Kurva Akurasi dan Kegagalan Pelatihan pada Dataset Pelatihan dan Validasi dengan Arsitektur *VGG-16Net*

Pada keempat pengujian dari ketinggian dan arsitektur yang berbeda dapat diketahui bahwa arsitektur *VGG-16Net* memerlukan waktu lebih lama sekitar 40 detik dibandingkan dengan arsitektur *LeNet-5* Modifikasi hanya 10 detik dalam melakukan pelatihan sepanjang

pembelajaran *epoch* sebanyak 50 lembar kerja. Perbandingan kurva akurasi dan kegagalan menunjukkan kedua arsitektur dalam kondisi *goodfit*, namun asitektur *LeNet-5* Modifikasi memiliki hasil yang lebih baik dalam pelatihan dengan akurasi akhir sebesar 0.9936 dan kegagalan 0.0193 pada ketinggian 100 meter dibandingkan dengan arsitektur *VGG-16Net* yang akurasi diperoleh 0.9923 dan kegagalan 0.0229 dalam skala nilai 0 sampai 1.

4.3 Hasil Evaluasi Dataset

Pada hasil evaluasi ini dilakukan dengan menggunakan model CNN yang dimiliki terhadap *dataset* pengujian dari ketiga area pulau. Tujuannya dengan melakukan prediksi terhadap kedua *class*, yaitu lahan sawah dan bukan lahan sawah. Sehingga dapat dilakukan perbandingan *class* diantara *dataset* pengujian dengan hasil prediksi dari model. Perbandingan ini dinyatakan dalam bentuk nilai 0 dan 1 yang menandakan identitas *class* pada citra sejumlah *dataset* pengujian yang sebanyak 20 citra di ketiga area.

4.3.1 Evaluasi Performa Model

Dalam mengevaluasi performa model yang dimiliki, dapat dilakukan dengan menggolongkan hasil klasifikasi pada perbandingan *class* antara *dataset* pengujian aktual dengan hasil prediksi dari model kedalam empat kategori, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN).

Tabel 4. 4 Confusion Matrix Terhadap Model pada Dataset Pengujian

n = Jumlah Citra	Dataset Pengujian Pulau Jawa	
	Prediksi	Prediksi
	Negatif (Bukan Sawah)	Positif (Sawah)
Aktual	True Negative (TN)	False Positive (FP)
Negatif (Bukan Sawah)		
Aktual	False Negative (FN)	True Positive (FN)
Positif (Sawah)		

Untuk mengklasifikasikan data evaluasi dan komparasi pada *confusion matrix*, peneliti

melakukan pengujian yang diperoleh pada empat perhitungan klasifikasi. Klasifikasi tersebut, yaitu klasifikasi akurasi (*classification accuracy*), presisi (*precision rate*), *recall rate*, dan *F1 score*. Berikut ini rumus perhitungan matematisnya :

1. Klasifikasi Akurasi

$$ClassifAcuraccy = (TP + TN) / (TP + TN + FP + FN) \quad (4.1)$$

2. Presisi

$$Precision\ Positive = TP / (TP + FP) \quad (4.2)$$

$$Precision\ Negative = TN / (TN + FN) \quad (4.3)$$

3. Recall Rate

$$Recall\ Rate\ Positive = TP / (TP + FN) \quad (4.4)$$

$$Recall\ Rate\ Negative = TN / (TN + FP) \quad (4.5)$$

4. F1 Score

$$F1\ Score = (2 \times (RR \times Precision)) / (RR + Precision) \quad (4.6)$$

1. Evaluasi performa model terhadap dataset pengujian pada ketinggian 100 meter menggunakan arsitektur *LeNet-5* Modifikasi

Tabel 4. 5 Hasil Pengukuran Parameter pada Confusion Matrix

No .	Objek Citra Ketinggian 100 Meter	Confusion Matrix				Jml	Class	
	Area Penelitian (citra)	TP	T N	FP	F N		B. S	S
1.	Pulau Jawa	8	10	0	2	20	10	10
2.	Pulau Kalimantan	8	10	0	2	20	10	10
3.	Pulau Sumatra	10	9	1	0	20	10	10

2. Evaluasi performa model terhadap dataset pengujian pada ketinggian 300 meter menggunakan arsitektur *LeNet-5* Modifikasi

Tabel 4. 6 Hasil Pengukuran Parameter pada Confusion Matrix

No .	Objek Citra Ketinggian 300 Meter	Confusion Matrix				J ml	Class	
	Area Penelitian (citra)	TP	T N	FP	F N		B. S	S
1.	Pulau Jawa	8	10	0	2	20	10	10
2.	Pulau Kalimantan	8	10	0	2	20	10	10
3.	Pulau Sumatra	10	9	1	0	20	10	10

3. Evaluasi performa model terhadap dataset pengujian pada ketinggian 100 meter menggunakan arsitektur *VGG-16Net*

Tabel 4. 7 Hasil Pengukuran Parameter pada *Confusion Matrix*

No .	Objek Citra Ketinggian 100 Meter	<i>Confusion Matrix</i>				J ml	<i>Class</i>	
	Area Penelitian (citra)	T P	T N	F P	F N		B. S	S
1.	Pulau Jawa	8	10	0	2	20	10	10
2.	Pulau Kalimantan	8	10	0	2	20	10	10
3.	Pulau Sumatra	10	9	1	0	20	10	10


4. Evaluasi performa model terhadap dataset pengujian pada ketinggian 300 meter menggunakan arsitektur *VGG-16Net*

Tabel 4. 8 Hasil Pengukuran Parameter pada *Confusion Matrix*

No .	Objek Citra Ketinggian 300 Meter	<i>Confusion Matrix</i>				J ml	<i>Class</i>	
	Area Penelitian (citra)	TP	T N	F P	F N		B. S	S
1.	Pulau Jawa	8	10	0	2	20	10	10
2.	Pulau Kalimantan	8	10	0	2	20	10	10
3.	Pulau Sumatra	10	9	1	0	20	10	10

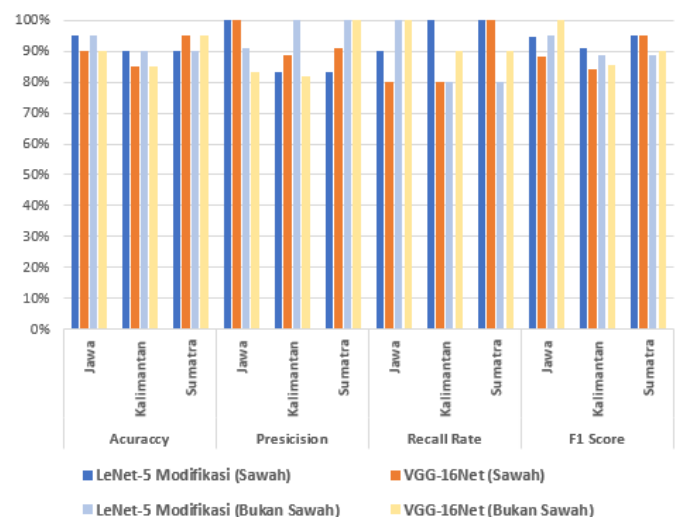
Sehingga berdasarkan dari keempat evaluasi performa model terhadap ketinggian dan arsitektur yang berbeda didapatkan empat hasil perhitungan performa model dalam klasifikasi dan prediksinya. Kemudian dapat dibandingkan antar evaluasi menjadi suatu grafik seperti Gambar 4.5 dan Gambar 4.6 berikut ini :

Grafik Perbandingan Ketiga Pulau Ketinggian 100 Meter Terhadap Performa Model dari Kedua Arsitektur



Gambar 4. 1 Grafik Perbandingan Ketiga Pulau Ketinggian 100 Meter Terhadap Performa Model dari Kedua Arsitektur

Grafik Perbandingan Ketiga Pulau Ketinggian 300 Meter Terhadap Performa Model dari Kedua Arsitektur



Gambar 4. 6 Grafik Perbandingan Ketiga Pulau Ketinggian 300 Meter Terhadap Performa Model dari Kedua Arsitektur

. Berdasarkan grafik pada gambar 4.5 dan 4.6 dapat diketahui bahwa hasil pada pulau Sumatra dengan arsitektur *VGG-16Net* yang digunakan dalam perhitungan klasifikasi dan prediksi tersebut mampu mencapai persentase keseluruhan 100% pada dikedua *class* citra sawah maupun citra bukan sawah. Sedangkan pada ketinggian 300 meter tergolong merata

penggunaan kedua arsitektur terhadap ketiga pulau yang diujikan.

4.3.1 Evaluasi Akurasi Dataset Pengujian dalam Piksel


Kemudian peneliti melakukan pengujian lainnya dari hasil performa model CNN tersebut pada *dataset* pengujian yang masih menggunakan citra dari folder *test*. Akan tetapi pengujian dilakukan dengan metode perhitungan akurasi pada jumlah piksel. Kedua *class* yang terdiri dari citra sawah dan citra bukan sawah masing-masing dihitung akurasi yang dimiliki pada pikselnya.

Tabel 4. 6 Hasil Akurasi dalam Piksel

No.	Ketinggian Objek	Arsitektur	Dataset Pengujian				
			Nama Objek	Class	Total Piksel	Jumlah Piksel Terdeteksi	Akurasi (%)
1.	100 Meter	LeNet-5 Modifikasi	b151	Sawah	685584 piksel	682266	99.516%
			o153	Bukan Sawah		684874	99.896%
		VGG-16Net	b151	Sawah		680403	99.244%
			o153	Bukan Sawah		683102	99.638%
2.	300 Meter	LeNet-5 Modifikasi	b151	Sawah		680650	99.280%
			o153	Bukan Sawah		684875	99.896%
		VGG-16Net	b151	Sawah		667208	97.319%
			o153	Bukan Sawah		685175	99.940%

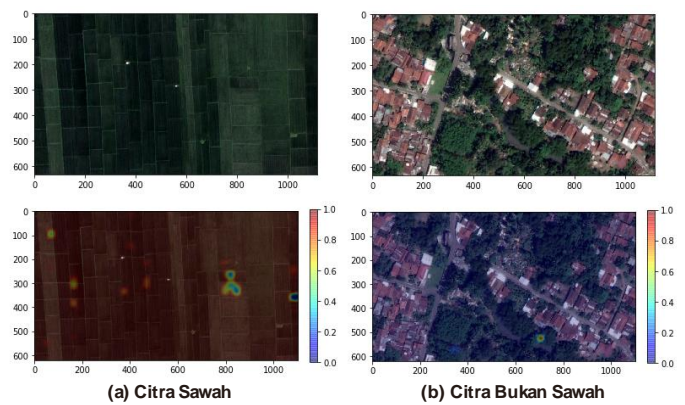
Pada evaluasi penelitian ini diambil *dataset* pengujian hanya pada 2 citra di pulau Jawa dan dibandingkan hasil akurasinya dalam kedua arsitekturnya. Akan terlihat kinerja performa model yang lebih baik dalam melakukan akurasi dari kedua arsitektur.

1. Evaluasi akurasi dalam piksel terhadap dataset pengujian pada ketinggian 100 meter menggunakan arsitektur *LeNet-5 Modifikasi*



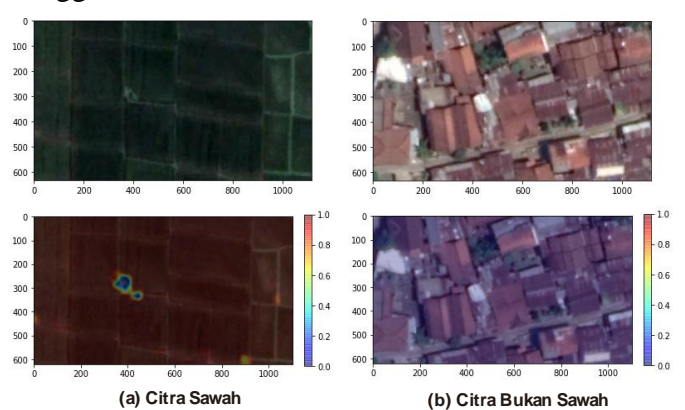
Gambar 4. 2 Identifikasi level nilai citra sawah dan bukan sawah

2. Evaluasi akurasi dalam piksel terhadap dataset pengujian pada ketinggian 300 meter menggunakan arsitektur *LeNet-5 Modifikasi*



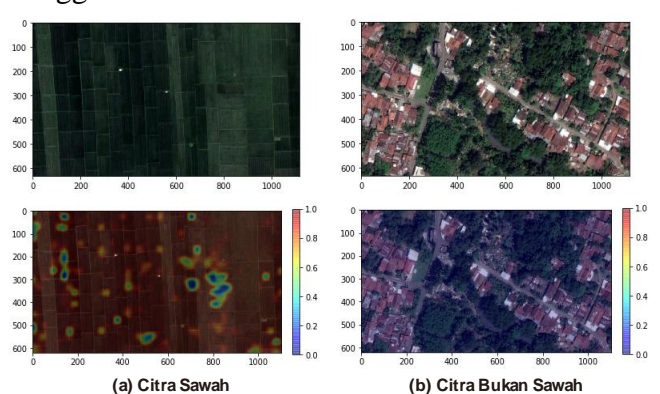
Gambar 4. 3 Identifikasi level nilai citra sawah dan bukan sawah

3. Evaluasi akurasi dalam piksel terhadap dataset pengujian pada ketinggian 100 meter menggunakan arsitektur *VGG-16Net*



Gambar 4. 4 Identifikasi level nilai citra sawah dan bukan sawah

4. Evaluasi akurasi dalam piksel terhadap dataset pengujian pada ketinggian 300 meter menggunakan arsitektur *VGG-16Net*



Gambar 4. 5 Identifikasi level nilai citra sawah dan bukan sawah

Berikut ini perbandingan akurasi ketiga pulau dengan jumlah sebanyak 60 citra di

kedua *class* dari ketinggian dan arsitektur yang berbeda, maka didapatkan hasilnya pada tabel 4.7.

Tabel 4. 7 Hasil Perbandingan Akurasi Ketiga Citra Terhadap Arsitektur

Ketinggian	Objek Area Penelitian	Arsitektur CNN	Jumlah Citra	Hasil Perbandingan Akurasi Ketiga Citra terhadap Arsitektur	
				Rata-rata Akurasi dalam Piksel (%)	
				Sawah	Bukan Sawah
100 Meter	Pulau Jawa	LeNet-5 Modif	20	99,70%	99,37%
		VGG-16Net	20	99,66%	96,44%
	Pulau Kalimantan	LeNet-5 Modif	20	98,01%	97,42%
		VGG-16Net	20	97,25%	95,63%
	Pulau Sumatra	LeNet-5 Modif	20	99,35%	98,56%
		VGG-16Net	20	99,19%	98,93%
300 Meter	Pulau Jawa	LeNet-5 Modif	20	99,37%	99,70%
		VGG-16Net	20	98,13%	98,73%
	Pulau Kalimantan	LeNet-5 Modif	20	91,75%	98,06%
		VGG-16Net	20	92,51%	94,97%
	Pulau Sumatra	LeNet-5 Modif	20	97,03%	99,35%
		VGG-16Net	20	96,94%	99,18%
Hasil Perbandingan Ketiga Akurasi					
Ketinggian 100 Meter		LeNet-5 Modif	60	99,02%	97,85%
		VGG-16Net	60	98,7%	97%
Ketinggian 300 Meter		LeNet-5 Modif	60	96,05%	98,82%
		VGG-16Net	60	95,86%	97,62%

Pada keseluruhan umum pada masing-masing ketinggiannya didapatkan perbandingan akurasi dalam piksel antar kedua arsitektur yang mana pada *LeNet-5* Modifikasi dengan ketinggian 100 meter diperoleh 99,02% pada citra sawah dan 97,85% pada citra bukan sawah. Sedangkan pada ketinggian 300 meter masing-masing citra pada arsitektur *LeNet-5* diperoleh hasil persentase sebesar 96,05% dan 97,85%.

4.4 Implementasi Terhadap Luasan Sawah

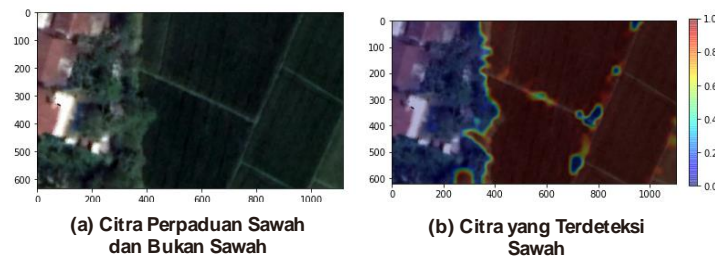
Peneliti hanya mengambil satu sampel citra dari 10 citra yang terdapat pada folder *test image*. Sampel yang diujikan dalam implementasi ini berlokasi di pulau Jawa dengan nama gambar "*test_image1*". Selain itu peneliti juga melakukan validasi lapangan yang bertujuan untuk mengukur panjangnya dalam meter yang dibandingkan panjang meter tersebut pada objek citra geografis yang sama.

4.4.1 Persentase Luas Lahan Sawah pada Sampel Pengujian

Tabel 4. 8 Hasil Persentase Luasan Sawah pada Sampel

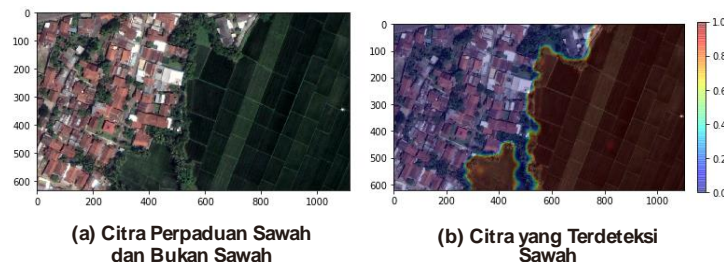
No.	Ketinggian Objek	Arsitektur	Dataset Pengujian			
			Nama Objek	Total Piksel	Jumlah Piksel Sawah	Persentase (%)
1.	100 Meter	LeNet-5 Modifikasi	test_image1	685584 piksel	454237	66.255%
		VGG-16Net	test_image1		442656	64.566%
2.	300 Meter	LeNet-5 Modifikasi	test_image1		359651	52.459%
		VGG-16Net	test_image1		339664	49.543%

1. Hasil persentase dan jumlah piksel pada dataset pengujian pada ketinggian 100 meter menggunakan arsitektur *LeNet-5* Modifikasi




Gambar 4. 6 Hasil Identifikasi Lahan Sawah pada Ketinggian 100 Meter dengan *LeNet-5* Modifikasi

2. Hasil persentase dan jumlah piksel pada dataset pengujian pada ketinggian 300 meter menggunakan arsitektur *LeNet-5* Modifikasi




Gambar 4. 7 Hasil Identifikasi Lahan Sawah pada Ketinggian 300 Meter dengan *LeNet-5* Modifikasi

3. Hasil persentase dan jumlah piksel pada dataset pengujian pada ketinggian 100 meter menggunakan arsitektur *VGG-16Net*



Gambar 4. 8 Hasil Identifikasi Lahan Sawah pada Ketinggian 100 Meter dengan VGG-16Net

4. Hasil persentase dan jumlah piksel pada dataset pengujian pada ketinggian 300 meter menggunakan arsitektur VGG-16Net



Gambar 4. 9 Hasil Identifikasi Lahan Sawah pada Ketinggian 300 Meter dengan VGG-16Net

Berdasarkan keempat hasil persentase dan jumlah piksel diketahui bahwa tingkat persentase dalam perbandingan luas lahan dengan satu citra dari ketinggian dengan arsitektur yang berbeda, diperoleh persentase tertinggi pada *LeNet-5* Modifikasi mencapai 66.255% pada ketinggian 100 meter, sedangkan pada ketinggian 300 meter mencapai 52.459%.

4.4.2 Perhitungan Luas Lahan Sawah pada Sampel Pengujian

Untuk metode perhitungan konversi meter per piksel dapat dilakukan mengambil objek yang sama pada lokasi pengukuran validasinya melalui fitur pengukuran panjang pada *Google Earth Pro* dan hingga mendapatkan panjang yang serupa dengan data validasi sebesar 2,71 meter. Kemudian gambar tersebut disimpan dan memperbesar citra mencapai batas maksimum dapat dilakukan pada perangkat lunak desain. Tabel 4. 9 Hasil Perhitungan Luas Lahan Sawah pada Sampel Pengujian

No.	Ketinggian Objek (meter)	Arsitektur	Sampel Pengujian Citra (<i>test_image1</i>)				
			Jumlah Piksel Sawah (piksel)	Validasi Pengukuran (meter)	Piksel Pengukuran (piksel)	Konversi Meter per Piksel (m/p)	Luas Lahan Sawah (<i>Ha</i>)
1.	100 Meter	<i>LeNet-5</i> Modifikasi	454237	2,71	40	0,068	0.21
		VGG-16Net	442656	2,71	40	0,068	0.204
2.	300 Meter	<i>LeNet-5</i> Modifikasi	359651	2,71	10	0,271	2.64
		VGG-16Net	339664	2,71	10	0,271	2.49

Pada tabel 4.11 menunjukkan beberapa nilai yang digunakan dalam melakukan perhitungan konversi meter per piksel dan perhitungan luas lahan sawah. Terdapat rumus yang dilakukan dalam melakukan konversi meter per piksel seperti pada rumus (4.10), berikut ini :

$$\text{Konversi } M \text{ per } P = (\text{Validasi } (m)) / (\text{piksel } (p)) \quad (4.10)$$

Untuk mendapatkan luas lahan pertanian sawah dapat dilakukan dengan perhitungan seperti pada rumus (4.11) berikut ini :

$$\text{Luas Lahan} = (\text{konversi } m \text{ per } p)^2 \times (\text{jumlah piksel yang terdeteksi}) \quad (4.11)$$

V. PENUTUP

5.1 Kesimpulan

Kesimpulan dalam penelitian ini adalah sebagai berikut.

1. Metode CPM dapat menghasilkan potongan citra menjadi 89.100 citra yang berukuran 56x56 piksel sehingga mengoptimalkan dalam identifikasi objek geografis lahan pertanian sawah.
2. Arsitektur *VGG-16Net* memerlukan waktu lebih lama sekitar 40 detik dibandingkan dengan arsitektur *LeNet-5* Modifikasi hanya 10 detik dalam melakukan pelatihan sepanjang pembelajaran epoch.
3. Perbandingan kurva akurasi dan kegagalan menunjukkan kedua arsitektur dalam kondisi goodfit, namun arsitektur *LeNet-5* Modifikasi memiliki hasil yang lebih baik dalam pelatihan dengan akurasi akhir sebesar 0.9936 dan kegagalan 0.0193 dibandingkan dengan arsitektur *VGG-16Net* yang akurasi diperoleh 0.9923 dan

kegagalan 0.0229 dalam skala nilai 0 sampai 1.

4. Hasil evaluasi performa model bahwa pada pulau Sumatra ketinggian 100 meter dengan VGG-16Net mencapai persentase keseluruhan 100%, sedangkan pada ketinggian 300 meter tergolong merata. Hal ini dikarenakan pengaruh lebih pada faktor kualitas citra, objek sawah dan ketinggian pada ketiga pulau yang diambil.
5. Pada keseluruhan umum pada masing-masing ketinggiannya didapatkan perbandingan akurasi dalam piksel antar kedua arsitektur yang mana pada LeNet-5 Modifikasi dengan ketinggian 100 meter diperoleh 99,02% pada citra sawah dan 97,85% pada citra bukan sawah. Sedangkan pada ketinggian 300 meter masing-masing citra pada arsitektur LeNet-5 diperoleh hasil persentase sebesar 96,05% dan 97,85%.
6. Perbandingan luas lahan dari ketinggian diperoleh persentase tertinggi pada *LeNet-5 Modifikasi* mencapai 66.255% pada ketinggian 100 meter, sedangkan pada ketinggian 300 meter mencapai 52.459%.

5.2 Saran

Berdasarkan penelitian yang telah dikerjakan penulis, penulis memberikan dapat memberikan beberapa saran guna pengembangan sistem selanjutnya.

1. Penggunaan deep learning dan metode CPM dapat juga diimplentasikan dalam pemetaan vegetasi komoditas pertanian lainnya, karena sangat baik dan mampu mendeteksi gambar dengan objek kecil, serta menawarkan penggunaannya yang murah dan efisien.
2. Untuk penelitian selanjutnya, dapat dikembangkan untuk identifikasi jenis padi pada lahan sawah dan pengenalan terhadap lahan sawah kering, serta diambil dataset dari pulau lainnya.
3. Dapat melakukan penelitian pada pelatihan dengan pembandingan tidak hanya dataset pelatihan yang random, tetapi bagaimana setiap lahan pertanian sawah dapat diujikan satu sama lain.

DAFTAR PUSTAKA

- [1] BPS Indonesia, “Statistika Indonesia 2019,” Badan Pusat Statistika. 2019.
- [2] W. Shuntaro, Kazuaki Sumi, dan Takeshi Ise, “Automatic vegetation identification in Google Earth images using a convolutional neural network: A case study for Japanese bamboo forests,” hlm. 3.
- [3] Badan Pusat Statistika, “PENGANTAR KERANGKA SAMPLE AREA,” 2017. [Daring]. Tersedia pada: https://ksa-nasional.info/a_pengantar.php [Diakses:18-Nov-2019].
- [4] Goodfellow, I. Bengio, dan Courville A, “Deep Learning,” MIT press. 2016.
- [5] Yosinski. J, Clune, I. Bengio, dan Lipson H, “How transferable are feature features in deep neural networks?,” Advances in Neural Information Processing Systems (Montreal), 2016, hlm. 3320–3328
- [6] LeCun, Y., Bottou, L., Bengio, Y., dan Haffner, P. “Gradient-based learning applied to document recognition. Proceedings of the IEEE”. 1998. 86(11):2278- 232.
- [7] LeCun, Y., Bengio, Y., dan Hinton. G, “Deep Learning“. Nature, 2016, hlm 436–444
- [8] MathWorks. “Graycoprops”. 2017. [Daring]. Tersedia pada <https://www.mathworks.com/help/images/ref/graycoprops.html?searchHightlight=> [Diakses; 19-Nov-2019]
- [9] Medium, “Neural Network,” 2004. [Daring]. Tersedia pada : <https://medium.com/@samuelsena/pengenal-deep-learning-8fbb7d8028ac> [Diakses; 18-Nov-2019]
- [10] Danukusumo, Kevin Pudi, “Implementasi Deep Learning Menggunakan Convolutional Neural Network untuk Klasifikasi Citra Candi Berbasis GPU”. Program Studi Teknik Informatika Fakultas Teknologi Industri : Universitas Atma Jaya Yogyakarta. 2017.
- [11] Rismiyati, ”Implementasi Convolution Neural Network Untuk Sortasi Mutu Salak

- Ekspor Berbasis Citra Digital,” Universitas Gajah Mada, Yogyakarta. 2016.
- [12] School of Computer Science Binus, “Dasar Pemahaman Neural Network,” [Daring]. Tersedia pada : <https://socs.binus.ac.id/2012/07/26/konsep-neural-network/> [Diakses:18-Jan-2019]
- [13] Medium, “Convolution Neural Network (CNN), ” [Daring]. Tersedia pada : <https://medium.com/@samuelsena/pengetahuan-deep-learning-part-7-convolutional-neural-network-cnn-b003b477dc94> [Diakses:11-Nov-2019]
- [14] John Paul Mueller dan Luca Massaron. “What is Google Colaboratory?”. [Daring]. Tersedia pada: <https://www.dummies.com/programming/python/what-is-google-colaboratory/>. [Diakses: 17-Nov-2019].
- [15] Chollet, François. 2018. Deep Learning with Python. Shelter Island: Manning Publications Co.
- [16] Geospatial Training Services. “Fundamentals Of Google Earth Pro”. 2016. [Daring]. Tersedia pada: <http://geospatialtraining.com/fundamentals-of-google-earth-pro/> [Diakses: 17-Nov-2019].
- [17] Mahi, A K. 2001. “Tata Ruang dan Pengelolaan Lingkungan Hidup”. PSL : Universitas Lampung. 2001.
- [18] Abdurrohman, Harits. “Sliding Window”. 2016. [Daring]. Tersedia pada: <https://medium.com/otakbeku/imgcv-2-sliding-window-2dda64723df0> [Diakses: 28-Nov-2019]
- [19] T. Ise, M. Minagawa, & M. Onishi . “Classifying 3 moss species by deep learning using the chopped picture method”. Open Journal of Ecology. 2018. 166–173.
- [20] Neurohive. “VGG16 – Convolutional Network for Classification and Detection”. [Daring]. Tersedia pada: <https://neurohive.io/en/popular-networks/vgg16/>. [Diakses: 18-Jan-2019].